

Gaudi AI 加速卡技术全景调研报告

执行摘要

对 AI 基础设施团队而言，Intel Gaudi 家族在 2026 年的现实定位已经相当清晰：**硬件上最有差异化的价值来自“片上以太网/RoCE 网络 + 大容量 HBM + 面向矩阵与非矩阵混合工作负载的异构架构”**，软件上最可用、最值得投入的主线则是 **PyTorch + SynapseAI/Intel Gaudi Software + Optimum-Habana + vLLM Hardware Plugin 或 Hugging Face TGI**。官方文档明确表明当前 Gaudi 软件套件围绕图编译器、运行时、TPC 内核库、HCCL、驱动/固件、Profiler 和 PyTorch 集成构建；最新文档版本覆盖 Gaudi 2 与 Gaudi 3，且当前默认执行路径已经转向 `eager + torch.compile`，Lazy mode 仅作为 legacy fallback。¹

从**推理**视角看，Gaudi 生态已经有可用的生产路径，但不是“CUDA/TensorRT-LLM 等价替代”。Gaudi 当前的强项是：对 Hugging Face 生态的深度耦合、对 LLM/VLM 的现成配方、片上 Ethernet/RDMA 带来的多机扩展简化，以及官方提供的 FP8/UINT4 推理文档、CustomOp/TPC SDK、Kubernetes Operator、监控与分析工具链。Gaudi 当前的弱项同样非常明确：**TensorFlow 已在 1.15 起停止支持，ONNX 在官方 PyTorch 支持矩阵中为 No，公共 PyTorch 支持仍带 preview/限制色彩，且部分不支持算子会回退到 CPU**。因此，Gaudi 更适合“愿意接受 PyTorch-first 与 shape-aware 调优范式”的团队，而不适合已经深度绑定 ONNX/TensorRT/CUDA 自定义核的存量平台直接平移。²

如果把结论压缩成基础设施决策建议，可以概括为三点。第一，**Gaudi 3 是当前真正值得评估的主力 SKU**；Gaudi 1 主要属于历史兼容路径，Gaudi 2 仍适合成本敏感或已部署集群的延续扩容，但面向大模型推理的新投入应优先看 Gaudi 3。第二，**Gaudi 推理的最佳落点不是“万能推理底座”，而是“以 HF/vLLM/TGI 为中心的 LLM/VLM 服务平台”**。第三，若你们团队的重点是多机推理、KV cache 规模、服务吞吐和以太网扩展治理，Gaudi 的网络设计值得认真评估；但若重点是最广泛的算子/框架覆盖、最成熟的 ONNX/TensorRT 路径、以及大量现成的第三方推理服务生态，NVIDIA 仍然最稳，AMD ROCm 在主流开源推理方面的广度也已明显超过 Gaudi。³

硬件架构与产品形态

Gaudi 的底层设计不是传统意义上“GPU 万能并行核”路线，而是**异构 AI SoC**。官方架构文档将其拆成三个主子系统：计算、内存和网络；计算部分由 **MME** 与 **TPC** 两类引擎组成。MME 负责可下沉到矩阵乘法的主干算子，如全连接、卷积、batched GEMM；TPC 则是面向深度学习非线性与非 GEMM 算子的**可编程 VLIW SIMD 处理器**。这意味着 Gaudi 的优化思路天然强调“图编译、流水线、算子融合和异构执行配平”，而不是只看某一类 Tensor Core 峰值。⁴

Gaudi 3 的公开硬件描述已经相当完整。官方架构页与技术白皮书都说明，**Gaudi 3 采用两个 compute die**，通过高带宽、低时延的 interposer bridge 连接，并对软件透明；合计提供 **8 个 MME、64 个 TPC、24 个 200Gbps RDMA NIC 端口、128GB HBM2e、3.7TB/s HBM 带宽**。官方架构页给出的顶层性能口径是 **FP8/BF16 1.8 PFLOPs**；而白皮书的详细计算表给出 **MME 矩阵计算 1678 TFLOPs，TPC 向量 BF16 28.7 TFLOPs**。这两者并不完全矛盾，但反映出**不同 Intel 材料采用了不同的汇总口径**；做选型时，建议以具体 SKU datasheet 和可复现实测为最后依据。⁵

Gaudi 2 的公开信息同样稳定：**24 个 100GbE RoCE v2 NIC、96GB HBM2E、2.45TB/s 带宽、48MB SRAM**，并且支持 FP32、TF32、BF16、FP16 与 FP8。Intel 的日文/韩文 Gaudi 3 白皮书表格还给出了与 Gaudi 3 的同口径对照：**Gaudi 2 约 432 BF16 MME TFLOPs、865 FP8 MME TFLOPs、24 个 TPC、2 个 MME**。与此同时，Intel 中文页和中文 Gaudi 2D 产品简介还表明，存在面向出口限制场景的 **Gaudi 2D/**


HL-225D 变体，其 TDP 与网络容量等参数与标准 Gaudi 2 并不完全相同，因此采购与调研时不能把“Gaudi 2D”和“标准 Gaudi 2”混为一谈。⁶

在产品形态上，Gaudi 3 同时覆盖 OAM 与 PCIe。官方技术白皮书描述 HL-325L OAM 支持最高 900W TDP；Gaudi 3 PCIe 产品简介则说明 HL-338 是一张 PCIe 5.0 x16、全高双槽、10.5 英寸、最高 600W TDP 的卡，带 128GB HBM2e 和 96MB SRAM，并支持用 top bridge 将 4 卡聚合为 900GB/s 带宽拓扑。对做企业推理平台的团队来说，PCIe 卡非常重要，因为它决定了 Gaudi 3 不只是“大型八卡整机/OAM”路线，也可以走标准 PCIe 服务器集成，尤其适合低延迟和中等规模 LLM 推理节点。⁷

下面这张表把 Gaudi 2、Gaudi 2D 与 Gaudi 3 的硬件口径拉齐到基础设施团队最关心的维度：

产品	公开架构形态	计算引擎	HBM	HBM 带宽	片上网络	主机接口	典型功耗/形态	备注与来源
Gaudi 2	官方公开文档未强调 chiplet，重点披露异构 SoC 架构	2 MME，24 TPC	96GB HBM2E	2.45–2.46 TB/s	24 × 100GbE RoCE v2，双向 600 GB/s	PCIe Gen4 x16，峰值 64 GB/s	标准资料常见 600W OAM	架构页、白皮书对照表、Intel 产品页。 ⁸
Gaudi 2D	面向受限市场的变体	2 MME，24 TPC	96GB HBM2E	中文资料给出 2.4 TB/s 级别	24 × 100GbE RoCE v2，产品简介写明网络容量可达 2.1 Tbps	OAM	单卡最高 450W	这是特定 SKU，不应直接代表标准 Gaudi 2。 ⁹
Gaudi 3 OAM	两个 compute die，经 interposer bridge 互连	8 MME，64 TPC	128GB HBM2e	3.7 TB/s	24 × 200Gbps RDMA，双向 1200 GB/s	PCIe Gen5 x16，峰值 128 GB/s	OAM，最高 900W	顶层性能口径 1.8 PFLOPs FP8/BF16；详细表格 1678 TFLOPs MME。 ⁵
Gaudi 3 PCIe HL-338	与 OAM 同代架构，PCIe 卡形态	8 MME，64 TPC	128GB HBM2e	3.7 TB/s	RoCE v2 片上端口 + 4 卡 bridge 900GB/s	PCIe 5.0 x16，128 GB/s	全高双槽 PCIe，最高 600W	面向低延迟/标准服务器集成很关键。 ¹⁰

从硬件选型逻辑看，Gaudi 的最大差异点不是单纯“显存更大”或“峰值算力更高”，而是把 scale-up 与 scale-out 所需的 Ethernet/RDMA 能力直接做进了芯片。这在多机推理、服务扩容、机架网络运维、以及避免额外 high-end fabric 绑定方面都很有现实意义。与此同时，Gaudi 3 的 128GB HBM2e 仍然显著小于 AMD MI325X 的 256GB HBM3E，也小于 NVIDIA H200 的 141GB HBM3e；对于超长上下文、超大 KV cache 或希望降低分片数的大模型推理，这一点会直接影响可服务模型的形状和 batch 策略。¹¹



上图反映了官方文档描述的 Gaudi 执行路径：模型先被桥接层与图编译器转成面向 MME/TPC/DMA/NIC 的执行配方，再通过多个异步 stream 进行并行与流水调度。¹²

软件栈与编译运行时

Gaudi 的软件总栈传统上被业界简称为 **SynapseAI**，在当前官方文档中更常见的表述是 **Intel Gaudi Software** 或 **Intel Gaudi Software Suite**。其核心组件包括：**Graph Compiler and Runtime**、**TPC Kernel Library**、**驱动与固件**、**HCCL**、**TPC SDK**、**Profiler**，以及面向 **PyTorch** 的桥接层。这套设计的关键不是“手写内核 + 运行时直调”而是“先图级 lowering，再用图编译器做融合、布局管理、并行化、流水化和内存管理，最后缓存 recipe 复用”。¹³

在 **PyTorch** 路径上，Gaudi 的当前状态需要精确理解。官方支持矩阵明确写道：**默认模式是 Eager mode + torch.compile**，**Lazy mode 是 legacy fallback**，已不再继续开发；同时，`torch.compile(backend="hpu_backend")` 是主要图执行路径，而 `torch.compile(backend="inductor")` 不是官方支持路径。理论上，**PyTorch** 推理与训练都支持，但支持矩阵也同时明确列出：**CUDA 原生不是支持设备，ONNX 导出/运行都是 No，稀疏张量/嵌套张量等也存在缺口**。这意味着 Gaudi 对 **PyTorch** 用户友好，但其兼容层并不是“把 **PyTorch** 的所有变体都自然吞掉”。¹⁴


更值得基础设施团队关注的是：**公共 PyTorch 支持已经存在，但仍带 preview 色彩**。官方 Theory of Operations 说明，桥接层兼容 Intel Gaudi **PyTorch fork** 与公共 **PyTorch 2.10.0**；公共 **PyTorch** 的支持目前限制于 `eager + torch.compile`，且**没有 dedicated Docker image**。从 ABI 角度看，v1.22 开始 `_GLIBCXX_USE_CXX11_ABI` 已切到与公共 **PyTorch** 一致的 `1`，旧版按 `0` 编译的扩展需要重编译。对推理平台团队而言，这两个点都非常关键：第一，它意味着你不必永远绑定 vendor fork；第二，它也意味着你们现有 **C++/PyBind** 扩展、轮子与容器 ABI 必须重新审查。¹⁵

如果你们有大量 **CUDA/PyTorch** 存量代码，Intel 官方建议走 **GPU Migration Toolkit**。其目标不是自动把所有性能问题解决，而是把 `torch.cuda` 等 GPU 依赖 API 替换为 HPU 对应调用，降低初次迁移的代码改动量。换句话说，它更像**兼容性加速器**，不是性能魔法棒。要拿到真正稳定的推理性能，后续仍然要做 shape 管理、图 warmup、算子核查、量化配置、HCCL/parallelism 策略与容器化收敛。¹⁶

最重要的断点是**TensorFlow 与 ONNX**。官方 release notes 已明确：**自 1.15.0 起 TensorFlow 不再支持，并且 Model References 中删除了所有 TensorFlow 模型**。而 **PyTorch** 支持矩阵中 OFFICIAL ONNX 相关条目是 **No/No**。这意味着若你们现在的生产推理主线建立在 TensorFlow Serving、ONNX Runtime、TRT-ONNX、或一套“多后端统一 ONNX 资产格式”的体系之上，Gaudi 不是低摩擦迁移对象；应把它视为一条新的、**PyTorch** 为核心的推理平台，而不是你们现有模型资产格式的平滑延展。¹⁷

当前公开的官方支持矩阵也给出了一个很实用的“落地版本窗口”：

组件	Gaudi 3 当前公开支持口径	实操含义	来源
Intel Gaudi Software	1.24.0	建议围绕 1.24 做新集群基线	18
PyTorch	2.10	新平台可以围绕 PyTorch 2.10 收敛，但需关注 ABI 与 preview 公共轮子路径	19
DeepSpeed	官方 fork 0.14.4 口径	多卡 LLM 推理/训练仍然常用	20
Intel Neural Compressor	3.8.1	FP8/低比特量化应视为主线能力	21
Optimum for Intel Gaudi	1.21.0	HF 工作流主入口	22
TGI	3.3.2	官方支持的 LLM 服务路径之一	23
vLLM Hardware Plugin for Intel Gaudi	0.17.1 / 0.19.0 / 0.19.1 / 0.21.0	需严格按矩阵配版本，不建议随意追最新 upstream	24
Kubernetes	1.33 / 1.34 / 1.35	K8s 集群版本选择有明确窗口	18



这个软件栈图背后的现实含义是：**Gaudi 的性能不是“只换设备名就有”，而是强依赖图编译、缓存与形状管理**。这也是它在推理场景里最常见的成功条件与失败根源。 25

推理框架、模型集成与算子优化

从 2026 年的成熟度看，Gaudi 推理生态的主线有四条：**Optimum-Habana、Hugging Face TGI、vLLM Hardware Plugin for Intel Gaudi，以及 SGLang**。Optimum-Habana 是 Hugging Face Transformers/

Diffusers 与 Gaudi HPU 之间的直接接口，覆盖单卡和多卡加载、训练与推理。TGI 是面向生产的 LLM 服务端；vLLM 插件则是当前 Gaudi 面向高吞吐 LLM 服务的另一条重要路线；SGLang 则反映出 Gaudi 近一年的推理生态仍在继续向新一代 serving/runtime 靠拢。 26

Optimum-Habana 的价值在于它把 Hugging Face 的模型加载、推理示例与 Gaudi 优化参数系统化；Intel 官方性能页中大量 LLM 吞吐数据也是基于 Optimum-Habana 测得。与此同时，官方 Model References 仓库仍然是可复现配方的重要来源；它包含生成式 AI、LLM 和 CV 的参考实现，且在 2026 年仍有更新。对 infra 团队而言，这意味着**Gaudi 成功率很大程度取决于你是否愿意接受“以官方参考仓库为真相源”**，而不是一开始就照搬你们现有 CUDA 推理脚本。 27

TGI 路径在 2025–2026 的一个重要变化，是**Gaudi 后端已向 Hugging Face 上游收敛**。Gaudi release notes 写明，旧的 `tgi-gaudi` 仓库会被弃用并迁移到 `huggingface/text-generation-inference`；TGI 的 Gaudi 后端文档还给出了现成 Docker 用法、sharding 参数、FP8 支持、VLM 示例以及 warmup/参数调优注意事项。对平台团队来说，这种 upstream 化非常重要，因为它减少了“厂商私有 fork 永久追版本”的维护税。 28

vLLM 路径则经历了另一种演变：**Intel 自有的 vLLM-fork 正在退场，而社区维护的 vLLM Hardware Plugin for Intel Gaudi 正成为主路径**。官方 release notes 已明确指出旧 fork 已 EOL，而支持矩阵则把重点放在插件版本与 Gaudi 软件版本的对应；最新 release notes 还说明该插件已经验证了包括 Qwen3-VL、Granite、Ernie4.5-VL、GPT-OSS、reranking 模型在内的一系列模型。这个变化的战略意义在于：Gaudi 不再试图永久维护一个平行 vLLM 世界，而是努力通过可插拔硬件后端进入 upstream 生态。 29

不过，要客观看待这件事。Gaudi 的 vLLM 路线虽然正在 upstream 化，但其公共文档仍然反复强调：**原始 vLLM 项目中的 Gaudi 支持不一定覆盖当前驱动/固件上的所有特性，Intel 自己的路径更强调“与最新驱动/固件对齐和保证可运行”**。这说明 Gaudi 的 vLLM 生态虽可用，但版本耦合仍然比较重。换成 infra 话语，就是：**不要把 vLLM 当作完全 vendor-agnostic 组件来管理，而要把它视为“硬件插件 + 特定 Gaudi 版本组合”的产品化工件**。 30

在模型覆盖方面，Gaudi 的 TGI 后端目前已列出很长的支持清单，包括 **Llama、Mixtral、Mistral、Qwen 2/3、Phi、Gemma、Granite、Cohere、Falcon、StarCoder、Baichuan，以及多种 VLM**。vLLM FAQ 与 release notes 也给出 Llama/Mistral/Mixtral/Qwen-VL/Granite/Ernie4.5-VL 等的验证情况。这说明在**主流开源 LLM/VLM 上**，Gaudi 的覆盖已达到“足以搭平台”的程度；但这并不等于“任何 HF 模型都能无缝跑”，因为 shape、量化格式、注意力实现、KV cache、Remote Code 与 custom layers 依然会决定成败。 31

在算子与内核层面，Gaudi 官方文档的态度是务实的。PyTorch Operators 文档直接说明：**支持的算子通常只覆盖 selected variants 和有限 optional parameters**；而 Software Suite 文档又明确表示，**不支持的算子会在 CPU 上执行**。这对推理平台是一条红线：一旦热点路径上出现 CPU fallback，端到端延迟与吞吐会迅速失控，尤其在 decode 阶段更明显。因此，对上模型前必须做 operator audit 和 profiler 验证，而不能只看“模型能跑”。 32

Gaudi 当前已经提供了比较完整的**自定义核与融合能力**：其一是 **PyTorch CustomOp API**，可以为新算子实现自定义 HPU kernel；其二是 **TPC SDK**，带 LLVM-based TPC-C 编译器、模拟器和调试器；其三是图编译器层面的 kernel library 集成，可以通过 `GC_KERNEL_PATH` 接入自定义 TPC 内核。官方还给出了面向特定模型块的 fused/custom op，例如为 Mixtral/LLaMA 中 MoE block 提供更适合 Gaudi 的实现，以及持续优化 FusedSDPA。对于需要把特定 attention/MoE 卷积 path 打磨到生产级的团队，这是一条可行但门槛不低的道路。 33

量化方面，Gaudi 在推理上已经把 **FP8 与 UINT4 明确推到主线**。官方文档写得很直接：**FP8 对 LLM 推理可将所需内存带宽减半，并把计算速度提升到 BF16 的两倍级别；UINT4 则进一步降低内存带宽压力**。当前推荐的量化工具是 **Intel Neural Compressor**，其已替代旧的 Habana Quantization Toolkit；官方推理量化页还说明，也支持用 **BitsAndBytes** 处理部分数据类型。需要注意的是，**剪枝/蒸馏更多是 INC 的通用能力，而不是像**

FP8/UINT4 那样在当前 Gaudi 推理文档里有成熟的一线 recipe。因此，如果你们以“压榨在线推理吞吐”为目标，优先级应是 FP8、KV cache 量化、图 warmup、shape 管理与 flash/fused attention，而不是先做剪枝。³⁴

下表给出一个面向推理工程的框架成熟度判断：

路径	当前状态	适用场景	主要限制/风险	来源
PyTorch 原生 + Gaudi Bridge	官方主线	自研推理、模型迁移、单模型调优	ONNX 不支持；不支持算子会 CPU fallback；公共 PyTorch 路径仍有限制	³⁵
Optimum-Habana	非常成熟	HF LLM/VLM/CV 快速落地	强依赖官方 recipe 与版本配齐	³⁶
Hugging Face TGI on Gaudi	成熟且上游化	生产 LLM 服务、连续批处理、分片	需要 warmup 和 shape 参数调优；仍以 HF 模型生态为中心	³⁷
vLLM Hardware Plugin for Intel Gaudi	已可生产评估	高吞吐 LLM 服务、插件化后端	与驱动/固件/插件版本耦合较重；旧 fork 已 EOL	³⁸
SGLang	新增且值得关注	新一代 LLM 服务	生态与文档深度仍在增长	³⁹
Triton Inference Server	可用，但不是当前优化主战场	已有 Triton 管理面、需要统一服务框架	官方公开优化重心更偏向 TGI/vLLM/SGLang	⁴⁰
TensorFlow	已退出主流	不建议新项目采用	1.15 起不再支持	⁴¹
ONNX	非官方主线	不建议作为 Gaudi 主资产格式	官方矩阵为 No	⁴²

通信栈与分布式推理能力

Gaudi 与 NVIDIA/AMD 最不同的地方之一，是**网络不是平台附属品，而是架构本体**。官方文档指出，Gaudi 是首批把 **RoCE v2 RDMA engines 直接集成到芯片** 中的深度学习处理器，用户可以在机内、机架内和跨机架都使用同一种基于标准以太网交换网络的扩展方式。对基础设施团队而言，这会影响的不仅是吞吐，还包括 NIC 规划、交换机策略、布线、拥塞测试、故障面和数据中心网络团队的协作方式。⁴³

在软件层，Gaudi 的 NCCL 等价物是 **HCCL**。官方文档把它定义为 Intel Gaudi 对标准 collective routines 的实现，并提供 **NCCL-compatible APIs**。HCCL 支持的主 collective primitives 包括 **AllReduce、Broadcast、Reduce、AllGather、ReduceScatter**，以及 **P2P 的 Send/Recv**。同时，PyTorch 分布式可通过 `backend='hccl'` 初始化，DDP、DeepSpeed、FSDP、DTensor 与 Tensor Parallel 也在支持矩阵中有不同程度的支持。⁴⁴


这里有一个很容易被忽略、但对大模型推理非常关键的细节：**HCCL 当前只支持 single device per process**。这与很多团队在 NCCL 上已经习惯的进程/设备组织方式有相似之处，但在容器调度、多租户隔离、vLLM/TGI 运行器封装和 launcher 设计上，仍然要按 Gaudi 的推荐方式去做，而不要想当然地移植你们原来的多卡单进程布局。⁴⁵

Gaudi 的 scale-out 还有一条很现实的优势：**除了用 Gaudi 片上 NIC，它还支持通过 Host NIC 走 OFI/libfabric 路径**。官方文档说明，HCCL 会自动选择最优的扩展方式，并给出优先级：优先使用 Gaudi NIC；其次是 Host NIC Gaudi Direct；再其次是经主机内存的 OFI 路径。对于 Host NIC Gaudi Direct，文档列出要求包括 **libfabric 版本、Linux 内核 5.12+、Gaudi 2/3 对 verbs provider 的支持** 等。也就是说，你们可以在标准网络架构上把 Gaudi 融入现有数据中心 fabrics，而不一定要接受完全封闭的平台 interconnect 思路。 46

从带宽口径看，Gaudi 3 官方网络配置文档给出了一组对 infra 很有用的数字：**每个 Gaudi 3 的 scale-up 理论单向带宽约 525 GB/s，双向约 1050 GB/s；每个 Gaudi 3 的 scale-out 带宽为每方向 75 GB/s，双向 150 GB/s；8 卡 HLS-3 box 级别的 scale-out 则是单向 600 GB/s，双向 1200 GB/s**。文档同时注明，Gaudi 2 的网络结构类似，但链路速率是 100Gbps，因此对应带宽基本减半。对于做多节点前缀缓存、分布式 prefill/decoding、或专家并行/MoE 的团队，这些数值比单卡 TFLOPs 更接近真实上线约束。 47

需要特别指出一个**API 与文档口径的边界问题**：HCCL 的“Supported Collective Primitives”主文档没有列出 `all2all`，但网络配置与拥塞测试文档又提到可使用 `all2all` 进行测试。这意味着 `all2all` 至少在 **demo/诊断层面存在，但是否将其视为所有版本下的正式主线 primitive，应按具体软件版本与官方示例再次确认**。如果你们的推理方案严重依赖 expert parallel / all-to-all 模式，务必在 PoC 期就把这一点前置验证。 48

在分布式模型并行层面，Gaudi 当前最稳的推理路线仍然是：**TGI/vLLM 自身的分片与连续批处理机制 + DeepSpeed/HCCL + 适度的张量并行**。支持矩阵表明，DeepSpeed、DDP、FSDP、DTensor 和 Tensor Parallel 都有支持，但 Pipeline Parallel 与 Distributed Elastic 仍为 No。对在线推理团队而言，这已经足够支撑大模型服务，但意味着你们不应期待“PyTorch 全量分布式技术栈在 Gaudi 上完全等价”。 49



这种“芯片内置 RoCE + 标准交换网络”的拓扑思维，是 Gaudi 与典型 GPU 平台最大的架构文化差异之一。

部署运维、容器化与开源成熟度

Gaudi 的运维栈比很多人想象得要完整。官方文档已经提供预构建容器镜像，并明确支持在 Ubuntu 22.04.5 和 24.04.3 上使用预构建 Docker 镜像；支持矩阵还给出了 Docker、Kubernetes、OpenShift、Slurm 等版本窗口。对于平台团队来说，这意味着 Gaudi 已经不仅是“跑 benchmark 的裸机设备”，而是有相对完整的云原生接入面。⁵¹

Kubernetes 方面，官方当前推荐路径是 Intel Gaudi Base Operator，它会自动管理驱动、Kubernetes device plugin、container runtime、feature discovery 和 monitoring tools。文档还显示，device plugin 会把设备暴露为 habana.ai/gaudi 资源。对已经在 GPU 集群中使用 Operator + device plugin 模式的团队来说，这种接入方式不会陌生；真正的差异在于你需要把 Gaudi 特定 runtime、监控 exporter、固件与驱动生命周期纳入集群平台治理。⁵²

在观测与运维工具方面，Gaudi 提供了相当于 nvidia-smi 的 hl-smi，以及 HLML/PYHLML 这样的管理库；固件更新有 hl-fw-loader；分析与剖析有 Intel Gaudi Profiler、Remote Trace Viewer；可用性验证还有 hl_qual 工具包。最新文档树中还出现了 Prometheus Metric Exporter、BMC Exporter 和 Redfish Data Model for Gaudi 3，表明硬件监控与平台集成已经进入更标准化阶段。对于生产服务平台，这些工具的重要性并不亚于模型框架本身。⁵³

需要注意的是，Gaudi 的 warmup/graph compile 对生产运维影响非常直接。TGI Gaudi 文档明确解释了固定 tensor shapes、graph compiler 生成 shape 相关二进制、server 启动阶段 warmup 的必要性，并提醒尤其在 FP8 模式下，warmup 可能需要数分钟。这意味着你们的服务设计必须把冷启动、灰度切换、实例预热、模型滚动升级和磁盘缓存策略纳入 SLO 设计；不能简单沿用一些 GPU 服务里“拉起即接流量”的思路。⁵⁴

多租户方面，官方文档给出了比较谨慎的指导：在 Docker 多 workload 场景下，虽然技术上能做部分卡分配，但推荐的组合主要是 2 卡和 4 卡成组，并建议按模块拓扑选择 HABANA_VISIBLE_MODULES。这说明 Gaudi 并非不能做细粒度分卡，但在当前官方支持下，最佳实践更偏向按拓扑切块分配，而不是完全任意切分。对在线推理平台，这会影响算力池切片方式与资源碎片化成本。⁵⁵

从开源成熟度看，Gaudi 生态有一个很鲜明的特征：关键基础设施组件已经开源，但整体社区体量与第三方渗透度仍明显低于 CUDA，也小于 ROCm 的主流推理生态。正面证据是，HabanaAI GitHub 组织中持续维护着 gaudi-pytorch-bridge、Model-References、Gaudi-tutorials、gaudi-base-operator、gaudi-device-plugin、gaudi-container-runtime 等仓库，且 Kubernetes/operator 相关仓库在 2026 年仍有更新；Optimum-Habana 在 Hugging Face 上游维护，vLLM-Gaudi 走社区维护插件路线。负面证据则是：Gaudi 仍依赖更严格的版本映射、较少的现成 SaaS/托管推理分发、以及更窄的框架兼容边界。⁵⁶

在许可证与支持通道上，Gaudi 也相对清晰。gaudi-pytorch-bridge、gaudi-base-operator、vllm-gaudi、optimum-habana 大体走 Apache-2.0；gaudi-device-plugin 则是 GPL-2.0。公开支持通道包括 Intel Gaudi Developer Community 和 Intel Community；另外，Intel 产品页也明确把购买与支持引导到 OEM 伙伴或 Intel 代表。对企业法务与平台团队来说，这意味着需要在“核心训练/推理代码 Apache-2.0 可内部分发”与“部分集群组件 GPL-2.0”之间做一次标准的开源合规审查。⁵⁷

下面这张小表适合直接交给平台、法务和 SRE 一起看：

项目	角色	许可证	备注	来源
HabanaAI/gaudi-pytorch-bridge	PyTorch 桥接与 HPU 核心运行能力	Apache-2.0	基础中的基础	⁵⁸

项目	角色	许可证	备注	来源
huggingface/optimum-habana	HF 到 Gaudi 的主入口	Apache-2.0	上游协作，适合模型侧团队	59
vllm-project/vllm-gaudi	vLLM 硬件插件	Apache-2.0	社区维护插件，需控版本	60
HabanaAI/gaudi-base-operator	K8s Operator	Apache-2.0	推荐的 K8s 部署方式	61
HabanaAI/gaudi-device-plugin	K8s 设备插件	GPL-2.0	集群层需做合规核查	62

基准、竞品对比、迁移路线与行动建议

先看官方或准官方可复现的推理性能数据。Intel 当前公开的 Gaudi 3 性能页给出了大量 LLM 吞吐行，适合拿来作集群容量估算。例如：Llama 3.1 8B 在 1 张 Gaudi 3 上，FP8、输入 128/输出 128、batch 1536 时可到 24364 tokens/s；在输入 128/输出 2048、batch 768 时约 18063 tokens/s。Llama 3.1 70B 在 2 张 Gaudi 3 上，128/2048 时约 6278 tokens/s；在 8 张 Gaudi 3 上，128/2048 时约 16891 tokens/s。Llama 3.1 405B 则要求最少 8 卡，128/2048 时约 4793 tokens/s。对应的 Gaudi 2 公开性能页显示，Llama 3.1 8B 1 卡在 128/128 时约 19873 tokens/s，70B 2 卡在 128/2048 时约 3894 tokens/s，70B 8 卡在 128/2048 时约 12681 tokens/s。换言之，Gaudi 3 对当前主流 LLM 推理的提升是明确而且可量化的。⁶³

但要注意，官方公开性能页目前显著偏向 LLM/生成式 AI。你要求的 BERT、ResNet 这类经典模型，在当前公开的 Gaudi 3 最新性能页中并没有像 LLM 那样系统给出新近的 inference latency/throughput 表；Gaudi 2 的历史 release notes 与 Model References 仍保留了 BERT-L inference、ResNet/BERT MLPerf 2.1 复现实验脚本 等内容，但在当前 1.24 的官方性能门户里，并没有同等新鲜度与同口径的 BERT/ResNet 推理表。也就是说：Gaudi 在一手公开材料中，已经把重心明显转向 LLM/VLM 推理，而不是继续用标准化表格去维护经典 NLP/CV 的线上推理指标。这个空白本身就是生态信号。⁶⁴

MLPerf 与第三方实测也能补充一些判断。Intel 新闻稿给出 Gaudi 2 在 MLPerf Inference v4.0 上，Llama v2-70B 为 8035.0 offline tokens/s、6287.5 server tokens/s，Stable Diffusion XL 为 6.26 offline samples/s、6.25 server queries/s，并说明用了 Hugging Face TGI 来支持连续批处理和张量并行。另一方面，Intel 2025 年发布的 Signal65/IBM Cloud 摘要写明，在 IBM Cloud 的实测里，Gaudi 3 对 H100 持续表现更高、对 H200 则是“高度竞争”，并且当时 Cloud 实例价格比 H100 低约 30%。Signal65 单独报告还说明，某些 Granite-3.1-8B 测试下 Gaudi 3 相对 H200 可在特定 batch 下高出几个百分点，而在 405B 测试中可高出 8.5%–21%。这些数据不能外推成“一定比 H200/H100 更快”，但足以说明：Gaudi 3 不是只靠低价换存在感，而是在部分真实 LLM 服务配置上有竞争力。⁶⁵

下面这张表把你们做 PoC 最常用的几组官方公开吞吐数字拉平：

模型与配置	Gaudi 2	Gaudi 3	读法	来源
Llama 3.1 8B, 1 卡, FP8, 128/128	19873 tok/s	24364 tok/s	适合短 prompt、短回复的上限吞吐估算	66
Llama 3.1 8B, 1 卡, FP8, 128/2048	15054 tok/s	18063 tok/s	更接近日常对话型服务	66

模型与配置	Gaudi 2	Gaudi 3	读法	来源
Llama 3.1 70B, 2 卡, FP8, 128/2048	3894 tok/s	6278 tok/s	中型 70B 服务的两卡口径	66
Llama 3.1 70B, 8 卡, FP8, 128/2048	12681 tok/s	16891 tok/s	八卡节点满编吞吐参考	66
Llama 3.1 405B, 8 卡, FP8, 128/2048	官方页未给 Gaudi 2 对应值	4793 tok/s	405B 属于 Gaudi 3 重点展示场景	67

从竞争对手视角看，Gaudi 3 的硬件比较应把“单包内存”“内存带宽”“互联模型”“软件生态广度”分开看，而不要只看一个 FP8 数字：

平台	显存容量	显存带宽	峰值推理计算口径	互联/扩展思路	软件主线	适合怎样的团队	来源
Intel Gaudi 3	128GB HBM2e	3.7 TB/s	顶层口径 1.8 PFLOPs FP8/ BF16；详细矩阵表为 1678 TFLOPs MME	24×200GbE 片上 RDMA，RoCE/OFI/ HCCL	SynapseAI/ Intel Gaudi Software、Optimum-Habana、TGI、vLLM Plugin	愿意采用 PyTorch-first、强调以太网 scale-out 的 infra 团队	68
NVIDIA H100	80GB HBM3	3.35 TB/s	FP8 Tensor Core 3958 TFLOPS	依平台形态使用 SXM/NVL 等 GPU fabric	CUDA、cuDNN、TensorRT-LLM、Triton、vLLM	追求最广生态与最稳生产工具链	69
NVIDIA H200	141GB HBM3e	4.8 TB/s	FP8 约 4 PFLOPS	同样依赖 NVIDIA 平台互联方案	CUDA、TensorRT-LLM、Triton、vLLM	长上下文、超大 KV cache、最成熟 LLM 推理栈	70
AMD MI300X	192GB HBM3	5.3 TB/s	官方更强调大模型容量与 ROCm 栈	OAM + Infinity Fabric 类互联	ROCm、vLLM、TGI	希望获得更大单包显存，且接受 ROCm 工程化	71
AMD MI325X	256GB HBM3E	6 TB/s	官方强调 FP16/ BF16/FP8/ INT8 全覆盖	OAM 形态	ROCm、vLLM、TGI	极重视显存与带宽，模型尽量少分片	72

基于上表，可以把Gaudi 与 NVIDIA/AMD 的竞争关系概括为一句话：**Gaudi 3 的核心卖点不是“绝对最强单卡”，而是“足够有竞争力的 LLM 推理性能 + 片上 Ethernet 网络 + 更开放的系统/软件定价思路”**；但在单包

显存、软件广度与现成生态上，它仍落后于 H200 和 MI325X 路线。这也是为什么 Intel 的公开材料经常同时强调性能、开放软件与成本效率，而不只强调单项峰值。 73


在成本与可获得性上，当前没有统一透明的官方“建议零售价”可以作为可靠的企业采购基线，因此这里不展开具体价格。公开一手材料能确认的是：Gaudi 3 已通过 OEM 伙伴进入 on-prem 路线，并已在 IBM Cloud 上提供公有云实例；旧的 Gaudi 1 则历史上在 AWS DL1 上可用；TGI 文档还提到 Intel Cloud 上的 Gaudi 2/3。这说明它并非“买不到”，但云与 OEM 覆盖度显然少于 NVIDIA。公开价格层面，Intel 的一些对比文档更多使用“基于公开信息和内部分析的 price/performance 估算”，而不是统一官方卡价。对采购与平台团队而言，这意味着 PoC 预算、交付周期、维保 SLA 和区域可用性必须前置询价，不能靠公开网页反推。 74

迁移检查清单

检查项	为什么重要	建议标准
确认模型主资产格式是否为 PyTorch/HF	ONNX/TensorFlow 不是 Gaudi 当前主线	非 PyTorch 资产需先做重构评估
为目标模型做 operator audit	不支持算子会回退 CPU	上线前必须做 profiler 与 fallback 核查
锁定官方支持矩阵版本	vLLM/TGI/Optimum 与驱动/固件耦合明显	先锁 Gaudi Software 1.24 基线
设计 shape/warmup 策略	图编译与缓存直接影响冷启动与抖动	预热脚本、缓存盘、滚动升级策略必须就位
量化优先级排序	Gaudi 推理主收益常来自 FP8/UINT4	先做 FP8，再评估 UINT4 和 KV cache 量化
分布式拓扑验证	HCCL、OFI、RoCE、Host NIC 路径都需实测	至少验证单机 8 卡与双机扩展两档
ABI/容器审计	公共 PyTorch/旧扩展 ABI 已变化	自研 wheel 与 C++ 扩展必须重编译验收
K8s/调度资源模型收敛	设备插件、Operator、多租户约束不同	统一 habana.ai/gaudi 资源治理与分卡策略

上表基本对应 Intel 官方“模型迁移”“优化检查表”“运行时与支持矩阵”的真实坑点，可以直接转成贵团队的落地验收单。 75

推荐路线图



建议路线不要一上来就做大规模分布式，而是按下面的顺序推进：

阶段	目标	关键产出	退出条件
单机单卡 PoC	验证模型可运行、无严重 fallback	1 个代表性 8B/7B 模型的 BF16 与 FP8 报告	P99 不出现明显 CPU 热点，吞吐达到官方同级别 70%+
单机多卡	验证 70B 级模型分片与 warmup 流程	2 卡/8 卡服务基线	HCCL、sharding、重启预热稳定
双机/多机	验证 OFI/RoCE、交换机配置和观测	网络基线与故障演练	扩展效率与稳定性达到业务阈值
Kubernetes 生产化	统一调度、镜像、监控与升级	Operator + device plugin + exporter 套件	可灰度发布、可回滚、可观测
成本优化	量化/缓存/批处理压榨性价比	FP8/UINT4、批处理政策、容量模型	单 token 成本与 SLA 达标

优先行动项与主要风险

我会把优先级排成这样：

首先要做的是**选一条主 serving 路径**。如果目标是大部分开源 LLM/VLM 的生产服务，优先比较 **TGI 与 vLLM Plugin** 两条路；如果你们的模型团队严重依赖 HF 配方和快速迭代，先从 **Optimum-Habana + TGI** 开始通常更稳。 ⁷⁶

其次要做的是**建立版本冻结与镜像策略**。Gaudi 的可用性高度依赖“驱动/固件/插件/框架/容器”一整套版本配平，支持矩阵与 backward/forward compatibility 表就是为此存在的。建议你们把 Gaudi 当作一个“整机软件发行版”来管，而不是把驱动与框架独立升级。 ⁷⁷

再次要做的是**围绕固定 shape 设计服务协议**。对话服务里最大输入、最大总 token、prefill batch token 上限、decode batch size、warmup 档位和缓存策略，应该被提升为平台配置项，而不是只藏在模型镜像里。Gaudi 的图编译特性决定了这些参数就是性能工程的一部分。 ⁵⁴

最后，需要在立项前就接受以下风险现实。**最大的兼容性风险**来自 ONNX/TensorFlow 非主线、公共 PyTorch 仍有限制、以及自定义/边缘算子 fallback 到 CPU；**最大的运维风险**来自 warmup、形状抖动、固件/驱动版本错配和多机网络调优；**最大的生态风险**来自 Gaudi 外部社区规模小于 CUDA/ROCm、云供应与第三方集成较少；**最大的商业风险**则是 Intel 公开材料虽强调性价比与可得性，但真实采购渠道、区域供货与售后 SLA 仍需逐一核实。 ⁷⁸

主要一手资料入口

以下这些资料最值得你们团队内部继续精读，并且都可以直接作为采购、PoC 与平台落地的“真相源”：

- **Gaudi Architecture**：硬件架构、MME/TPC/NIC/HBM 总览。 ⁷⁹
- **Intel Gaudi Software Suite**：编译器、运行时、HCCL、TPC SDK、PyTorch 集成。 ¹³
- **PyTorch Support Matrix**：执行模式、分布式支持、ONNX/TensorFlow 边界。 ¹⁴
- **PyTorch Gaudi Theory of Operations**：公共 PyTorch、ABI、recipe cache、内存管理。 ¹⁵
- **Support Matrix 1.24**：驱动、固件、容器、K8s、PyTorch、vLLM/TGI/Optimum 版本窗口。 ¹⁸
- **Gaudi 3 Technical Paper / PCIe Product Brief**：Gaudi 3 OAM 与 PCIe 形态、TDP、HBM、接口。 ⁸⁰
- **Model Performance Data**：Gaudi 2 / Gaudi 3 官方公开 LLM 吞吐。 ⁶³

- **TGI Gaudi Backend** 与 **vLLM Hardware Plugin for Intel Gaudi**: 当前最重要的两条 LLM serving 路线。 ⁸¹
- **Kubernetes Base Operator / Device Plugin / hl-smi / hl-fw-loader / Profiler**: 平台化部署与运维核心。 ⁸²

综合判断，如果你们团队的目标是构建一套以 **PyTorch/Hugging Face 模型为主、强调多机以太网扩展、愿意为 FP8/shape/warmup 做性能工程** 的推理平台，那么 Gaudi 3 是值得认真进入 PoC 清单的一条路线；如果目标是 **统一 ONNX/TensorRT 资产、最低迁移摩擦、最大第三方生态覆盖**，那么 Gaudi 更适合作为专项平台而非通用推理底座。这个边界越早接受，后面的投入回报越高。 ⁸³

¹ ¹² ¹³ ²⁵ ⁴⁴ ⁸³ https://docs.habana.ai/en/latest/Gaudi_Overview/Intel_Gaudi_Software_Suite.html

https://docs.habana.ai/en/latest/Gaudi_Overview/Intel_Gaudi_Software_Suite.html

² ¹⁷ ⁴¹ https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.15.0.html

https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.15.0.html

³ ⁴ ⁵ ⁶ ⁸ ¹¹ ⁴³ ⁵⁰ ⁶⁸ ⁷⁹ https://docs.habana.ai/en/latest/Gaudi_Overview/Gaudi_Architecture.html

https://docs.habana.ai/en/latest/Gaudi_Overview/Gaudi_Architecture.html

⁷ ⁸⁰ <https://cdrdv2-public.intel.com/817486/gaudi-3-ai-accelerator-white-paper.pdf>

<https://cdrdv2-public.intel.com/817486/gaudi-3-ai-accelerator-white-paper.pdf>

⁹ <https://www.intel.cn/content/dam/www/central-libraries/us/en/documents/2024-09/24-cmf405-gaudi-2d-ai-accelerator-hl-225d-oam-mezzanine-card-product-brief.pdf>

<https://www.intel.cn/content/dam/www/central-libraries/us/en/documents/2024-09/24-cmf405-gaudi-2d-ai-accelerator-hl-225d-oam-mezzanine-card-product-brief.pdf>

¹⁰ https://cdrdv2-public.intel.com/817488/Gaudi%203%20PCIe%20Product%20Brief_RB_1_V6.pdf

https://cdrdv2-public.intel.com/817488/Gaudi%203%20PCIe%20Product%20Brief_RB_1_V6.pdf

¹⁴ ³⁵ ⁴² ⁴⁹ ⁷⁸ https://docs.habana.ai/en/latest/PyTorch/Reference/PyTorch_Support_Matrix.html

https://docs.habana.ai/en/latest/PyTorch/Reference/PyTorch_Support_Matrix.html

¹⁵ https://docs.habana.ai/en/latest/PyTorch/Reference/PyTorch_Gaudi_Theory_of_Operations.html

https://docs.habana.ai/en/latest/PyTorch/Reference/PyTorch_Gaudi_Theory_of_Operations.html

¹⁶ https://docs.habana.ai/en/latest/PyTorch/PyTorch_Model_Porting/GPU_Migration_Toolkit/GPU_Migration_Toolkit.html

https://docs.habana.ai/en/latest/PyTorch/PyTorch_Model_Porting/GPU_Migration_Toolkit/GPU_Migration_Toolkit.html

¹⁸ ¹⁹ ²⁰ ²¹ ²² ²³ ²⁴ ⁷⁷ https://docs.habana.ai/en/latest/Support_Matrix/Support_Matrix.html

https://docs.habana.ai/en/latest/Support_Matrix/Support_Matrix.html

²⁶ ³⁶ ⁵⁹ <https://github.com/huggingface/optimum-habana>

<https://github.com/huggingface/optimum-habana>

²⁷ ⁶³ ⁶⁷ <https://www.intel.com/content/www/us/en/developer/platform/gaudi/model-performance-1-19.html>

<https://www.intel.com/content/www/us/en/developer/platform/gaudi/model-performance-1-19.html>

²⁸ https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.20.html

https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.20.html

- ²⁹ https://docs.habana.ai/en/latest/Release_Notes/GAUDI_Release_Notes.html
https://docs.habana.ai/en/latest/Release_Notes/GAUDI_Release_Notes.html
- ³⁰ https://docs.habana.ai/en/latest/PyTorch/Inference_on_PyTorch/vLLM_Inference/vLLM_FAQs.html
https://docs.habana.ai/en/latest/PyTorch/Inference_on_PyTorch/vLLM_Inference/vLLM_FAQs.html
- ³¹ ³⁷ ⁵⁴ ⁷⁶ ⁸¹ <https://github.com/huggingface/text-generation-inference/blob/main/docs/source/backends/audi.md>
<https://github.com/huggingface/text-generation-inference/blob/main/docs/source/backends/audi.md>
- ³² https://docs.habana.ai/en/latest/PyTorch/Reference/Pytorch_Operators/Pytorch_Operators.html
https://docs.habana.ai/en/latest/PyTorch/Reference/Pytorch_Operators/Pytorch_Operators.html
- ³³ https://docs.habana.ai/en/latest/PyTorch/Reference/PyTorch_CustomOp_API/page_index.html
https://docs.habana.ai/en/latest/PyTorch/Reference/PyTorch_CustomOp_API/page_index.html
- ³⁴ https://docs.habana.ai/en/latest/PyTorch/Inference_on_PyTorch/Quantization/Inference_Using_FP8.html
https://docs.habana.ai/en/latest/PyTorch/Inference_on_PyTorch/Quantization/Inference_Using_FP8.html
- ³⁸ ⁶⁰ <https://github.com/vllm-project/vllm-gaudi>
<https://github.com/vllm-project/vllm-gaudi>
- ³⁹ https://docs.habana.ai/en/latest/PyTorch/SGLang_Inference/SGLang_Inference.html
https://docs.habana.ai/en/latest/PyTorch/SGLang_Inference/SGLang_Inference.html
- ⁴⁰ https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.9.0.html
https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.9.0.html
- ⁴⁵ https://docs.habana.ai/en/latest/API_Reference_Guides/HCCCL_APIs/Using_HCCCL.html
https://docs.habana.ai/en/latest/API_Reference_Guides/HCCCL_APIs/Using_HCCCL.html
- ⁴⁶ https://docs.habana.ai/en/latest/API_Reference_Guides/HCCCL_APIs/Scale_Out_via_Host_NIC.html
https://docs.habana.ai/en/latest/API_Reference_Guides/HCCCL_APIs/Scale_Out_via_Host_NIC.html
- ⁴⁷ https://docs.habana.ai/en/latest/Management_and_Monitoring/Network_Configuration/index.html
https://docs.habana.ai/en/latest/Management_and_Monitoring/Network_Configuration/index.html
- ⁴⁸ https://docs.habana.ai/en/latest/API_Reference_Guides/HCCCL_APIs/Overview.html
https://docs.habana.ai/en/latest/API_Reference_Guides/HCCCL_APIs/Overview.html
- ⁵¹ https://docs.habana.ai/en/latest/Installation_Guide/Additional_Installation/Docker_Installation.html
https://docs.habana.ai/en/latest/Installation_Guide/Additional_Installation/Docker_Installation.html
- ⁵² https://docs.habana.ai/en/latest/Installation_Guide/Additional_Installation/Kubernetes_Installation/index.html
https://docs.habana.ai/en/latest/Installation_Guide/Additional_Installation/Kubernetes_Installation/index.html
- ⁵³ https://docs.habana.ai/en/latest/Management_and_Monitoring/Embedded_System_Tools_Guide/System_Management_Interface_Tool.html
https://docs.habana.ai/en/latest/Management_and_Monitoring/Embedded_System_Tools_Guide/System_Management_Interface_Tool.html
- ⁵⁵ https://docs.habana.ai/en/latest/Orchestration/Multiple_Tenants_on_HPU/Multiple_Dockers_each_with_Single_Workload.html
https://docs.habana.ai/en/latest/Orchestration/Multiple_Tenants_on_HPU/Multiple_Dockers_each_with_Single_Workload.html

- 56 <https://github.com/orgs/HabanaAI/repositories>
<https://github.com/orgs/HabanaAI/repositories>
- 57 58 <https://github.com/HabanaAI/gaudi-pytorch-bridge>
<https://github.com/HabanaAI/gaudi-pytorch-bridge>
- 61 <https://github.com/HabanaAI/gaudi-base-operator>
<https://github.com/HabanaAI/gaudi-base-operator>
- 62 <https://github.com/HabanaAI/gaudi-device-plugin>
<https://github.com/HabanaAI/gaudi-device-plugin>
- 64 https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.7.1.html
https://docs.habana.ai/en/latest/Release_Notes/Release%20Notes%20v1.7.1.html
- 65 <https://newsroom.intel.com/artificial-intelligence/new-gaudi-2-xeon-performance-ai-inference>
<https://newsroom.intel.com/artificial-intelligence/new-gaudi-2-xeon-performance-ai-inference>
- 66 <https://www.intel.com/content/www/us/en/developer/platform/gaudi/model-performance-gaudi2-inference.html>
<https://www.intel.com/content/www/us/en/developer/platform/gaudi/model-performance-gaudi2-inference.html>
- 69 H100 GPU
https://www.nvidia.com/en-us/data-center/h100/?utm_source=chatgpt.com
- 70 nvidia h200 gpu
https://www.nvidia.com/en-us/data-center/h200/?utm_source=chatgpt.com
- 71 AMD Instinct MI300X Accelerator
https://www.amd.com/content/dam/amd/en/documents/instinct-tech-docs/data-sheets/amd-instinct-mi300x-data-sheet.pdf?utm_source=chatgpt.com
- 72 [instinct-mi325x-datasheet.pdf](https://www.amd.com/content/dam/amd/en/documents/instinct-tech-docs/product-briefs/instinct-mi325x-datasheet.pdf)
<https://www.amd.com/content/dam/amd/en/documents/instinct-tech-docs/product-briefs/instinct-mi325x-datasheet.pdf>
[utm_source=chatgpt.com](https://www.amd.com/content/dam/amd/en/documents/instinct-tech-docs/product-briefs/instinct-mi325x-datasheet.pdf)
- 73 <https://www.intc.com/news-events/press-releases/detail/1689/intel-unleashes-enterprise-ai-with-gaudi-3-ai-open-systems>
<https://www.intc.com/news-events/press-releases/detail/1689/intel-unleashes-enterprise-ai-with-gaudi-3-ai-open-systems>
- 74 <https://www.intel.com/content/www/us/en/products/details/processors/ai-accelerators/gaudi.html>
<https://www.intel.com/content/www/us/en/products/details/processors/ai-accelerators/gaudi.html>
- 75 https://docs.habana.ai/en/latest/PyTorch/Model_Optimization_PyTorch/Optimization_Getting_Started.html
https://docs.habana.ai/en/latest/PyTorch/Model_Optimization_PyTorch/Optimization_Getting_Started.html
- 82 https://docs.habana.ai/en/latest/Installation_Guide/Additional_Installation/Kubernetes_Installation/Kubernetes_Operator.html
https://docs.habana.ai/en/latest/Installation_Guide/Additional_Installation/Kubernetes_Installation/Kubernetes_Operator.html